Proyecto - Minería de Datos

Electiva II Minería de Datos · Universidad de Nariño · 6 al 28 de noviembre de 2026

Su grupo es un equipo interno de una alcaldía. La alcaldía tiene un conjunto de artículos de Wikipedia en español para una secretaría. Sus lectores son colegas que están empezando a trabajar en esa secretaría y deben decidir qué temas estudiar para ponerse al día con los conceptos que el trabajo requiere.

El producto del proyecto es una lista de artículos para los nuevos integrantes del equipo. La lista es un inicio de lectura. No demuestra que un artículo sea cierto, y no le dice a la secretaría qué decisión tomar. Su grupo la entrega al cierre del curso, en el cuaderno de la semana 3 y en la presentación del 28 de noviembre.

Los datos

Cada grupo recibe un archivo de datos base. Cada fila es un artículo de Wikipedia con los atributos que se deben utilizar en el proceso de data mining.

Grupo	Secretaría	Archivo
G1	Agricultura	`agricultura.csv`
G2	Salud mental	`salud-mental.csv`
G3	Medio ambiente	`medio-ambiente.csv`
G4	Inclusión Social	`inclusion-social.csv`
G5	Vivienda	`vivienda.csv`

Su grupo es libre de enriquecer su conjunto de datos como lo considere adecuado.

Desarrollo del proyecto

A lo largo del curso el grupo aprende varias maneras de analizar los datos. En la semana 1 buscan pares de palabras que se repiten y los comparan con una línea base. En la semana 2 agrupan artículos parecidos y prueban un filtro de texto, contando aciertos y errores. En la semana 3 describen un artículo por el lugar que ocupa entre los demás y predicen una etiqueta a partir de otros atributos del artículo.

El trabajo avanza iterativamente, como propone CRISP-DM. En la primera semana el grupo fija la pregunta a resolver. Esa pregunta se mantiene. En cada semana siguiente el grupo añade lo que encontró, lo compara con lo que ya tenía y analiza sus resultados. El informe reporta las iteraciones: las decisiones, los métodos, la comparación entre ellos y la evolución de la lista de artículos. Cada artículo que quede en la lista final debe apoyarse en los resultados del proceso iterativo.
