# Proyecto - Minería de Datos

**Electiva II Minería de Datos · Universidad de Nariño · 6 al 28 de noviembre de 2026**

---

## La historia

Ustedes son un equipo interno de un concejo. El concejo tiene una base de artículos científicos y un conjunto de artículos de Wikipedia en español para un departamento. Sus lectores son colegas que deben decidir qué abrir primero. Su lista es un punto de partida para leer. No es evidencia que el concejo pueda citar.

---

## La nota

| Componente | Peso |
|---|---|
| Semana 1 (cuaderno grupal 60% + reflexión individual 40%) | 20% |
| Semana 2 (cuaderno grupal 60% + reflexión individual 40%) | 20% |
| Semana 3 (cuaderno grupal 60% + reflexión individual 40%) | 20% |
| Proyecto final (cuaderno del proyecto 70% + reflexión final 30%) | 40% |

El cuaderno grupal de la semana 3 es el proyecto.

---

## Sus dos trabajos

**En los laboratorios** usan una colección de artículos sobre nutrición. Ningún grupo recibe ese departamento. Deciden qué artículos debe leer el equipo y qué filtro los puso en la lista. Un número alto de citas, por sí solo, no es razón para conservar un artículo.

**En el proyecto** cada grupo tiene un departamento de Wikipedia. Aquí "departamento" es un área de trabajo del concejo, no un departamento del país.

| Grupo | Departamento | Archivo |
|---|---|---|
| G1 | Pobreza | `pobreza.csv` |
| G2 | Vivienda | `vivienda.csv` |
| G3 | Medio ambiente | `medio-ambiente.csv` |
| G4 | Agricultura | `agricultura.csv` |
| G5 | Salud mental | `salud-mental.csv` |

Deciden qué artículos debe abrir primero una persona nueva para unirse al trabajo de ese departamento. La lista es un inicio de lectura. No es investigación que el concejo vaya a citar. Un artículo que es central solo porque enlaza a todo es una advertencia, no una elección automática.

---

## Reglas de los datos

- Los patrones que conserven salen de las palabras del texto (el `lead` o el resumen).
- Un par de categorías que se repite es la clasificación que ya hicieron los editores. No es un patrón encontrado.
- Las categorías pueden servir para definir parecido en la semana 2. El informe dice que esas etiquetas venían dadas.
- La pregunta tiene que caber en su archivo. Un tema que los artículos no cubren no es un proyecto.

---

## El cuaderno

Un cuaderno por semana. Las mismas seis secciones cada semana: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. Cada semana agrega trabajo nuevo solo en las secciones de esa semana. Las otras secciones siguen en el cuaderno.

| Semana | Qué agrega el grupo |
|---|---|
| 1 | La pregunta, los pasos, el estándar y el uso. Patrones que se repiten, comparados con otros patrones y con una línea base que el grupo define |
| 2 | Grupos de artículos parecidos, artículos que no encajan en ningún grupo, y un filtro de texto con aciertos y errores |
| 3 | Un artículo descrito por su lugar entre los demás. Una predicción con aciertos y errores. La lista de inicio, con al menos dos resultados anteriores, y qué la cambiaría |

---

## Entregas

| Qué | Cuándo (hora Colombia) |
|---|---|
| Cuaderno grupal semana 1 | Martes 10 nov, 23:59 |
| Reflexión semana 1 | Miércoles 11 nov, 23:59 |
| Cuaderno grupal semana 2 | Martes 17 nov, 23:59 |
| Reflexión semana 2 | Miércoles 18 nov, 23:59 |
| Cuaderno grupal semana 3 (el proyecto) | Martes 24 nov, 23:59 |
| Reflexión semana 3 | Miércoles 25 nov, 23:59 |
| Presentación | Sábado 28 nov |
| ZIP del proyecto | Martes 1 dic, 23:59 |
| Reflexión del proyecto | Miércoles 2 dic, 23:59 |

La presentación no agrega minería nueva. Presenta el cuaderno de la semana 3.

---