Proyecto - Minería de Datos

Electiva II Minería de Datos · Universidad de Nariño · 6 al 28 de noviembre de 2026

De qué trata el proyecto

Su grupo es un equipo interno de una alcaldía. La alcaldía tiene un conjunto de artículos de Wikipedia en español para una secretaría. Sus lectores son colegas que están empezando a trabajar en esa secretaría y deben decidir qué temas estudiar primero.

El producto del proyecto es una lista de artículos para abrir primero. La lista es un inicio de lectura. No demuestra que un artículo sea cierto, y no le dice a la secretaría qué decisión tomar. El grupo la entrega al cierre del curso, en el cuaderno de la semana 3 y en la presentación del 28 de noviembre. El sábado 7 de noviembre solo la empieza.

Los datos

Cada grupo recibe un archivo. Cada fila es un artículo de Wikipedia. El texto para buscar patrones de palabras es la columna `lead`, la entradilla del artículo.

Grupo	Secretaría	Archivo
G1	Pobreza	`pobreza.csv`
G2	Vivienda	`vivienda.csv`
G3	Medio ambiente	`medio-ambiente.csv`
G4	Agricultura	`agricultura.csv`
G5	Salud mental	`salud-mental.csv`

La pregunta tiene que poder responderse con los artículos de ese archivo. Si el archivo no habla del tema, ese tema no es el proyecto. Las categorías ya las pusieron quienes editaron Wikipedia, así que un par de categorías que se repite no cuenta como un patrón encontrado por el grupo.

Cómo se construye la lista

A lo largo del curso el grupo aprende varias maneras de mirar los mismos artículos, y la lista tiene que usarlas. En la semana 1 buscan pares de palabras que se repiten en la entradilla y los comparan con una línea base. En la semana 2 agrupan artículos parecidos y prueban un filtro de texto, contando aciertos y errores. En la semana 3 describen un artículo por el lugar que ocupa entre los demás y predicen una etiqueta a partir de otros atributos del artículo.

Un solo método no basta. Cada artículo que quede en la lista debe apoyarse en al menos dos de esos resultados. El grupo escribe qué hecho sacaría a un artículo de la lista. Un artículo que queda en el centro solo porque enlaza con muchos otros es una alerta, no una razón suficiente para incluirlo.

El sábado 7 de noviembre

Lean este documento con su grupo y empiecen la tarjeta de la pregunta: la pregunta de la persona nueva, los pasos, el estándar de una buena lista y el uso que esa persona puede darle. El cuaderno de

la semana 1 guarda esa tarjeta en `pregunta.json` y los pares de palabras en `outputs/patrones.csv`. Esos dos archivos son el primer resultado. No son la lista terminada.
