Semana 2 - plan de sesión (14 nov 2026)

Electiva II Minería de Datos · Maestría en Estadística Aplicada · UDENAR · B-2026

Sábado 14 nov 2026 · 07:00-13:00 (hora Colombia) · Lecciones **L3** (Grupos, atípicos y qué significa un grupo) + **L4** (Extracción de texto y ejemplos marcados)

Antes del sábado

- Lean los dos textos de la semana y llenen el diario (`learning-journal-week-2.docx`). No se califica. Las dos lecturas van en el correo del curso.
- Ejecuten los cuadernos individuales **L3** y **L4** en Colab. Anoten las celdas que no pudieron ejecutar.
- Tengan a mano `pregunta.json` y `outputs/patrones.csv` de la semana 1. El cuaderno grupal los carga al inicio.

Cronograma del sábado

Hora (CO)	Duración	Actividad
07:00-07:15	15 min	Apertura
07:15-08:00	45 min	Discusión de lecturas - en su grupo
08:00-08:30	30 min	Plenaria - un portavoz por grupo
08:30-08:45	15 min	Descanso
08:45-10:00	1 h 15	Recorrido en vivo por el cuaderno grupal de la semana 2
10:00-10:45	45 min	Cada grupo marca `marcas.csv` y después corre los modelos de texto
10:45-11:00	15 min	Descanso
11:00-12:20	1 h 20	Trabajo en el proyecto
12:20-12:50	30 min	Plenaria sobre el proyecto
12:50-13:00	10 min	Cierre y plazos

Discusión de lecturas (45 min en grupo + 30 min plenaria)

En su grupo (45 min): usen las notas del diario y las preguntas de la tabla. Preparen un mensaje corto para la plenaria.

Lectura	Pregunta para discutir
Jain (2010)	Jain dice que no hay un mejor método para agrupar y que el número de grupos depende del uso. ¿Qué tendría que pasar para que ustedes digan que un grupo existe? ¿Quién elige el número de grupos?

Devlin et al. (2019)	En la Lección 4 usamos el codificador como vectores fijos, sin ajustarlo. ¿Qué ganamos y qué perdemos? ¿Por qué un conjunto marcado pequeño no basta para decir que el codificador gana?
Las dos	Formar grupos no usa marcas. El filtro de texto sí. ¿Quién debería marcar los ejemplos, y en qué fase de CRISP-DM se decide qué cuenta como un artículo para leer?

Plenaria (30 min): un portavoz por grupo, máximo 5 minutos.

Recorrido en vivo por el cuaderno grupal (1 h 15)

El docente ejecuta el cuaderno grupal de la semana 2. Ustedes lo ejecutan al mismo tiempo, cada grupo con su archivo. En los huecos del cuaderno no damos la respuesta. Mostramos qué celda de la Lección 3 o de la Lección 4 deben seguir.

Ejercicio del cuaderno	Qué hacemos
0 y 1. Configuración y comprensión del negocio y de los datos	La tarjeta de la semana 1 y qué significaría un grupo para la persona nueva
2. Preparación (Pasos 2.1 y 2.2)	La entradilla (`lead`), el vocabulario con el umbral de la semana 1 y la reducción con SVD
2. Grupos, L3 (Pasos 2.3 a 2.5)	k-means, mezcla gaussiana y HDBSCAN. Los artículos que quedan sin grupo. La silueta frente a la línea base
3. Filtro de texto, L4	Las palabras clave del Paso 2.1, escritas antes de ver resultados. Cómo se genera `marcas.csv` (Paso 3.1). Los modelos se corren después de marcar

Al iniciar, ejecuten el Paso 0.2, que descarga el codificador (`multilingual-e5-small`, unos 470 MB).

Trabajo en grupo (45 min)

Primero marcan, después corren los modelos.

- El cuaderno escribe `marcas.csv` con el título y la entradilla de 60 a 67 artículos. Son unos 16 por persona, 20 en G1.
- Cada persona lee la entradilla y marca si el artículo trata del tema de su grupo. No miren las categorías de los editores.
- Suban el archivo lleno al cuaderno y corran los modelos de texto.

Cada grupo deja estos archivos:

- `marcas.csv`: sus marcas. Con ellas se cuentan los aciertos y los errores del filtro de texto.
- `outputs/grupos.csv`: el grupo de cada artículo. Un artículo en un grupo de HDBSCAN que la persona nueva lee recibe el apoyo `read_group`. El ruido no lo recibe.
- `outputs/texto.csv`: lo que dice cada filtro de texto, con sus marcas. Un artículo que TF-IDF manda a leer recibe el apoyo `text_says_read`.
- `outputs/en_vista.csv`: los tres apoyos por artículo (pares de palabras, grupos, texto) y cuántos tiene.

Con estos archivos la lista de inicio tiene tres apoyos posibles. Un artículo queda en vista con dos. La semana 3 suma el lugar en el grafo y la predicción, y cierra la lista.

Trabajo en el proyecto (1 h 20 + 30 min plenaria)

Abran su plantilla de requerimientos de la semana 1. Hoy añadan a la sección 4, Objetivos de minería, lo que encontró el grupo y qué hecho sacaría un artículo de la lista.

Plenaria (30 min): cada grupo comparte un artículo de `outputs/en_vista.csv` con dos apoyos y una duda.

Entregas semana 2 (después del sábado)

Entrega	Plazo (Colombia)
ZIP grupal `week-2-<group_id>.zip` con `week-2-group-<group_id>.ipynb`, `pregunta.json`, `marcas.csv`, `outputs/grupos.csv`, `outputs/texto.csv` y `outputs/en_vista.csv`	**Martes 17 nov 2026, 23:59**
Reflexión `week-2-reflection-<apellido>-<inicial>.pdf` (primer apellido e inicial del nombre)	**Miércoles 18 nov 2026, 23:59**
Documento de requerimientos del proyecto	Se entrega con el ZIP del proyecto, **martes 1 dic 2026**

Plantillas: reflexión semana 2 · requerimientos del proyecto

Enlaces semana 2: Hub · Lección 3 · Lección 4
