Semana 2 - plan de sesión (14 nov 2026)

Electiva II Minería de Datos · Maestría en Estadística Aplicada · UDENAR · B-2026

Sábado 14 nov 2026 · 07:00-13:00 (hora Colombia) · Lecciones **L3** (Grupos, atípicos y qué significa un grupo) + **L4** (Extracción de texto y ejemplos marcados)

Antes del sábado

- Vean las dos grabaciones (L3 y L4). Cada una trae la teoría y el paso a paso del cuaderno.
- Ejecuten los cuadernos individuales **L3** y **L4** en Colab. Anoten las celdas que no pudieron ejecutar.
- Lean los dos textos de la semana y llenen el diario (`learning-journal-week-2.docx`). No se califica.
- Tengan a mano el `pregunta.json` de su grupo de la semana 1. El cuaderno grupal lo carga al inicio.

Cronograma del sábado

Hora (CO)	Duración	Actividad
07:00-07:15	15 min	Apertura
07:15-08:00	45 min	Discusión de lecturas - en su grupo
08:00-08:30	30 min	Plenaria - un portavoz por grupo
08:30-08:45	15 min	Descanso
08:45-10:00	1 h 15	Recorrido en vivo por el cuaderno grupal de la semana 2
10:00-10:45	45 min	Cada grupo marca su conjunto marcado y termina las secciones de la semana
10:45-11:00	15 min	Descanso
11:00-12:20	1 h 20	Trabajo en el proyecto
12:20-12:50	30 min	Plenaria sobre el proyecto
12:50-13:00	10 min	Cierre y plazos

Discusión de lecturas (45 min en grupo + 30 min plenaria)

En su grupo (45 min): usen las notas del diario y las preguntas de la tabla. Preparen un mensaje corto para la plenaria.

Lectura	Pregunta para discutir
Jain (2010)	Jain dice que no existe un mejor método para formar grupos y que el número de grupos depende del uso. En el laboratorio de la Lección 3 la silueta es baja (de 0,058 a 0,075 para k de 3 a 8) y no marca un k natural. ¿Qué tendría que pasar para que ustedes digan que un grupo existe? ¿Quién elige el número de grupos?

Devlin et al. (2019)	BERT se puede ajustar a una tarea o usar como un extractor fijo de vectores. En la Lección 4 usamos el codificador fijo. ¿Qué ganamos y qué perdemos? ¿Por qué un conjunto marcado pequeño no basta para decir que el codificador gana?
Las dos	Formar grupos no usa marcas. Clasificar textos sí las usa. ¿Quién debería marcar los ejemplos, y en qué fase de CRISP-DM se decide qué cuenta como un artículo para leer?

Plenaria (30 min): un portavoz por grupo, máximo 5 minutos.

Recorrido en vivo por el cuaderno grupal (1 h 15)

El docente ejecuta el cuaderno grupal de la semana 2. Ustedes lo ejecutan al mismo tiempo, cada grupo con su archivo. Paramos donde Python o el método no queden claros. En los huecos del cuaderno no damos la respuesta. Mostramos qué celda de la Lección 3 o de la Lección 4 deben seguir.

Parte	Qué hacemos
Comprensión del negocio y de los datos	La pregunta de la semana 1 y qué significaría un grupo para una persona nueva
Preparación	El campo `lead`, el vocabulario con el mismo umbral de soporte, la reducción con SVD y la lista de palabras clave escrita antes de ver resultados
Modelado y evaluación (L3)	k-means, mezcla gaussiana y HDBSCAN. Los artículos que quedan sin grupo. La silueta frente a la línea base
Modelado y evaluación (L4)	Lista de palabras clave escrita antes de ver resultados. Cómo se genera `marcas.csv`. Los modelos de texto se corren después de marcar, a las 10:00.

Al iniciar, ejecuten la celda que descarga el codificador (`multilingual-e5-small`). Es grande (unos 470 MB) y la descarga puede tardar.

Trabajo en grupo (45 min)

Primero marcan, después corren los modelos.

- El cuaderno escribe `marcas.csv` con el título y el `lead` de 60 a 67 entradas de su archivo, según el grupo. Son unas 16 o 17 por persona. En G1, que tiene tres integrantes, son 20.
- Repártanse las filas. Cada persona lee el `lead` y marca si la entrada trata del tema que busca su grupo. El cuaderno dice cómo escribir la marca.
- No miren las categorías de los editores mientras marcan. Después el cuaderno compara sus marcas con esas categorías.
- Suban el archivo lleno al cuaderno. Una celda revisa que estén todas las filas y que no haya celdas vacías.
- Después corran los modelos de texto y terminen las secciones de la semana.

Trabajo en el proyecto (1 h 20 + 30 min plenaria)

Abran su plantilla de requerimientos de la semana 1. Hoy avancen dos secciones:

- **Sección 4, Estándar:** qué resultados apoyan a un artículo. Ya tienen tres: los patrones de la Lección 2, los grupos de la Lección 3 y el filtro de texto de la Lección 4.
- **Sección 5, Datos:** qué columna usa el grupo en cada lección.

Plenaria (30 min): cada grupo comparte un artículo que queda en vista con dos apoyos y una duda.

Entregas semana 2 (después del sábado)

Entrega	Plazo (Colombia)
ZIP grupal `week-2-<group_id>.zip`	**Martes 17 nov 2026, 23:59**
Reflexión `week-2-reflection-<apellido>-<inicial>.pdf` (primer apellido e inicial del nombre)	**Miércoles 18 nov 2026, 23:59**
Documento de requerimientos del proyecto	Se entrega con el ZIP del proyecto, **martes 1 dic 2026**

Plantillas: reflexión semana 2 · requerimientos del proyecto

Enlaces semana 2: Hub · Lección 3 · Lección 4
